


Концепция агента и среды

Лекция 2





Олег Орловский

ИТ-лидер команды развития кадровых сервисов


Блоки лекции



1. Главное из прошлой лекции
2. Агент и среда: состояние, действие, вознаграждение, один шаг
3. Доход и дисконтирование: что агент на самом деле максимизирует
4. Стратегия: как выбрать действие
5. Подводим итоги



Цели лекции



1. Познакомиться с формальным языком: схема «агент — среда», обозначения S , A , R , t
2. Узнать, как задаётся цель во времени: траектория, эпизод, доход, дисконтирование γ
3. Изучить, как агент выбирает действия: стратегия и ϵ -жадность
4. Научиться описывать задачу формально: состояние, действия, вознаграждение, γ , тип задачи

Вспомним прошлую лекцию



Reinforcement Learning (RL) — обучение с подкреплением; метод машинного обучения, при котором система учится выбирать действия на основе получаемых последствий или вознаграждений.

Главное:

- RL — это про выбор действий, а не про прогноз
- Базовая четвёрка **и цикл их взаимодействия**:
 - агент (тот, кто принимает решения),
 - действие (то, что агент может сделать),
 - среда (мир, внутри которого действует агент),
 - вознаграждение (числовой сигнал)
- Агент учится на последствиях: действие сейчас — результат потом
- Вознаграждение — способ задать цель: важен не «плюс сейчас», а суммарный результат
- «Попробовать новое или использовать проверенное» — уже про стратегию, а не про отдельный шаг

Язык для RL: зачем он нужен



от интуиции — к языку


- Интуиция: система действует, получает обратную связь и учится — словами
- Язык: те же идеи точными обозначениями — состояния, действия, вознаграждения, время



формализация — запись задачи точными обозначениями и правилами, по которым можно производить вычисления

интуиции хватает, чтобы понять; формального языка — чтобы посчитать и написать код

Схема взаимодействия: кто с кем и как



агент влияет на среду, но не контролирует её
среда возвращает и состояние, и вознаграждение

Обозначения S, A, R, t



- S — множество состояний: все ситуации, в которых агент может оказаться
- A — множество действий: всё, что агент может сделать
- R — множество вознаграждений: числа, которыми оцениваем результат
- t — время, номер шага

S1	S2	S3	S4 выход +10
S5	S6	S7	S8
S9	S10	S11	S12

S — 12 клеток (3 × 4)

A — ↑ вверх ↓ вниз ← влево → вправо (4 действия)

R — -1 за шаг, +10 за выход




состояние (state) — описание текущей ситуации, по которому агент принимает решение.
Вознаграждение (reward, R) — числовая оценка результата

Один шаг во времени



- действие — в момент t , результат — в момент $t+1$
- Вознаграждение приходит после действия — отсюда индекс $t+1$

$$S_t \rightarrow a_t \rightarrow r_{t+1}, S_{t+1}$$



Время — это номер шага: $t = 0, 1, 2, 3, \dots$. Агент стоит в s_0 (шаг 0), шагнул — оказался в s_1 (шаг 1). У действия номер 0, а у награды и нового состояния — 1: награда приходит на переходе.




шаг взаимодействия (timestep) — переход «состояние → действие → вознаграждение → новое состояние»

От шага к эпизоду: траектория и терминальное состояние



- Траектория — полная история взаимодействия
- Терминальное состояние — момент, когда взаимодействие прекращается (в примере — S4, выход)
- Эпизод — всё от начального состояния до терминального
- Примеры: лабиринт, партия в шахматы, смена таксиста

$$S_0 \rightarrow a_0 \rightarrow r_1 \rightarrow S_1 \rightarrow a_1 \rightarrow r_2 \rightarrow S_2 \rightarrow \dots$$



Клетка — это место (S1, S2, ...); состояние — место плюс номер шага (s0, s1, ...); t — сам номер шага. Агент стоит в клетке S1 — значит состояние s0 и шаг t = 0; шагнул в S2 — теперь s1 и t = 1.



Траектория — последовательность «состояние, действие, вознаграждение» от начала до конца. Эпизод — одно взаимодействие агента со средой от начального состояния до терминального

Терминальное состояние — состояние, в котором взаимодействие прекращается

Вознаграждение — сигнал, а не цель



цель агента — максимизация суммарного вознаграждения за всё время взаимодействия, а не немедленного вознаграждения

- Вознаграждение — сигнал «здесь и сейчас», оценка за один шаг
- Цель — не максимум следующего вознаграждения, а сумма за всё время

Примеры:

- шахматист (съесть пешку сейчас или тихий ход к мату через десять ходов);
- зарплата (потратить за день или отложить на квартиру)



Цель агента — не «плюс сейчас», а суммарный результат за всё время: одна оценка за шаг против суммы всех оценок.

А как эту сумму посчитать?

Доход: сумма будущих вознаграждений



- G — доход;
- R_{t+1} — первое вознаграждение после момента t ;
- γ (гамма) — вес, который уменьшает дальние вознаграждения

доход — сумма будущих вознаграждений с убывающим весом

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

Зачем нужно дисконтирование



- γ — число от нуля до единицы: 0 — смотрим только на следующий шаг, 1 — смотрим в бесконечность
- Математическая причина: бесконечная сумма расходится
- Смысловая: сегодняшнее вознаграждение ценнее будущего
- Инженерная: дальнейшее будущее хуже предсказуемо

$$1/(1 - \gamma)$$

 коэффициент дисконтирования $\gamma \in [0,1]$ — насколько агент учитывает будущее.
Эффективный горизонт $\approx 1/(1 - \gamma)$

Что меняет γ : считаем на числах



γ	Доход G	Смотрит вперёд примерно на
0	1	0 шагов
0,5	2	2 шага
0,9	10	10 шагов
0,99	100	100 шагов



Откуда $1/(1-\gamma)$: обозначим сумму S ; тогда $S = 1 + \gamma S$, потому что всё после первой единицы — та же сумма, умноженная на γ ; значит $S = 1/(1-\gamma)$

γ — это настройка, которую задаём мы

Где можно $\gamma = 1$: эпизодические и непрерывные задачи



- Эпизодические: партия, лабиринт, поездка — есть естественный конец и терминальное состояние; здесь можно $\gamma = 1$
- Непрерывные: климат в здании, торговый алгоритм, дата-центр — конца нет; γ обязательно меньше единицы
- Правило внизу: $\gamma = 1$ — только там, где задача заканчивается



Эпизодическая задача: взаимодействие кончается, эпизод за эпизодом — вознаграждений конечное число, значит можно $\gamma = 1$.
Непрерывная задача: конца нет, сумма бесконечного числа вознаграждений расходится — γ обязательно меньше единицы.



**эпизодическая задача — задача с естественным концом (терминальным состоянием).
Непрерывная задача — задача без конца. Обесценивание — учёт будущих вознаграждений с убывающим весом**

Стратегия: правило выбора действий



Стратегия (policy, π) — правило выбора действий, отображение состояний в действия.

Детерминированная — всегда одно и то же действие.

Стохастическая — действия выбираются с вероятностями

- Стратегия π — правило выбора действий, отображение состояний в действия
- Таблица «состояния $\times$ действия», в клетках — вероятности выбора
- Два вида: детерминированная (всегда одно действие) и стохастическая (с вероятностями)

Стратегия — это то, что мы ищем

ε-жадная стратегия: исследовать или использовать



Исследование (exploration) — пробовать новые действия.


Использование (exploitation) — выбирать то, что уже кажется лучшим.

ε-жадная стратегия — с вероятностью ε случайное действие, иначе лучшее известное.

ε - (эпсилон) — вероятность случайного действия, настройка, которую задаём мы.

случайное действие

лучшее известное действие



10% решений

90% решений

- $\epsilon = 0$ — всегда только лучшее известное: новое не пробуем никогда
- $\epsilon = 1$ — всегда случайно: узнанное не используем вовсе

ε — это настройка, которую задаём мы: маленькое ε — редко пробуем новое, большое — часто.

Что нужно вынести из этой лекции, чтобы понять следующую



- + Схема и обозначения: агент, среда, S , A , R , t — на них встанут вероятности переходов
- + Один шаг: $S_t \rightarrow a_t \rightarrow R_{t+1}, S_{t+1}$; из него вырастет $p(s', r | s, a)$
- + Доход G и дисконтирование γ — на них встанут уравнения Беллмана
- + Тип задачи: эпизодическая или непрерывная — от этого зависит, можно ли $\gamma = 1$





ДЗ на следующую лекцию



Процесс из 8 шагов:

- + бэклог → сбор требований → анализ требований → передача архитектору → постановки → разработка → тестирование → вывод в прод

Дайте определения для этого процесса:

- + кто агент
- + какие действия доступны
- + какие есть шаги (что считается одним шагом)
- + что такое состояние
- + какие могут быть вознаграждения

Каждое определение — одна фраза про ваш процесс: не назвать, а определить и провести границу (где агент, а где среда)

- + Уровень 1 — все пять определений.
- + Уровень 2 — добавьте тип задачи (эпизодическая или непрерывная) и γ с обоснованием.
- + Уровень 3 — добавьте стратегию: правило выбора действий для вашего агента. Покажите траекторию одной задачи и посчитайте доход G_t при $\gamma = 0,9$.
- + Будет плюсом: как в вашем процессе выглядела бы ϵ -жадная стратегия — что здесь случайное действие, что лучшее известное и какое ϵ вы бы взяли.



Спасибо за внимание

